

Analisa
CNN (Convolutional Neural Network) – Visual Data
Klasifikasi Ikan
Elieser Pasaribu - 1103223209

1. Arsitektur CNN dengan X lapisan konvolusi menghasilkan akurasi training 98% tetapi akurasi validasi 62%. Jelaskan fenomena vanishing gradient yang mungkin terjadi pada lapisan awal, dan bagaimana cara memitigasinya! Mengapa penambahan Batch Normalization setelah lapisan konvolusi ke-Y justru memperburuk generalisasi, serta strategi alternatif untuk menstabilkan pembelajaran?

Jawab:

Dalam arsitektur CNN dengan banyak lapisan konvolusi, akurasi training yang tinggi (98%) tetapi akurasi validasi rendah (62%) dapat mengindikasikan masalah vanishing gradient pada lapisan awal. Fenomena ini terjadi karena gradien yang melewati banyak lapisan menjadi sangat kecil akibat aktivasi seperti Sigmoid/Tanh yang memiliki derivatif bernilai kecil atau inisialisasi berat yang tidak optimal. Akibatnya, lapisan awal hampir tidak ter-update, sehingga model gagal menangkap pola mendasar dan hanya mengandalkan fitur lapisan akhir, menyebabkan overfitting. Untuk memitigasinya, dapat digunakan aktivasi ReLU/Leaky ReLU, inisialisasi berat yang tepat (seperti He Initialization), atau penambahan residual connection seperti pada ResNet untuk memungkinkan aliran gradien yang lebih lancar. Di sisi lain, penambahan Batch Normalization (BN) setelah lapisan konvolusi tertentu justru dapat memperburuk generalisasi karena ketergantungannya pada statistik mini-batch. Jika ukuran batch kecil, normalisasi menjadi noisy dan tidak stabil, sehingga model overfit terhadap variasi batch.

2. Ketika melatih CNN dari nol, loss training stagnan di nilai tinggi setelah XXX(3 digit epoch) epoch. Identifikasi tiga penyebab potensial terkait laju pembelajaran (learning rate), inisialisasi berat, atau kompleksitas model! Mengapa penggunaan Cyclic Learning Rate dapat membantu model keluar dari local minima, dan bagaimana momentum pada optimizer SGD memengaruhi konvergensi?

Jawab:

Ketika melatih CNN dari nol, stagnasi loss training pada nilai tinggi setelah ratusan epoch dapat disebabkan oleh tiga faktor utama terkait learning rate, inisialisasi bobot, dan kompleksitas model. Pertama, learning rate yang tidak tepat—terlalu kecil membuat model terjebak di local minima, sementara terlalu besar menyebabkan osilasi tanpa konvergensi. Kedua, inisialisasi bobot yang buruk, seperti nilai terlalu kecil atau distribusi simetris, dapat menghambat aliran gradien selama backpropagation. Ketiga, ketidaksesuaian kompleksitas model dengan data, baik terlalu sederhana

(underfitting) maupun terlalu dalam tanpa mekanisme pendukung seperti residual connection, membuat model sulit mempelajari pola data secara efektif. Untuk mengatasi stagnasi ini, Cyclic Learning Rate (CLR) dapat menjadi solusi dengan cara secara periodik memvariasikan learning rate antara batas bawah dan atas. Strategi ini memungkinkan model "melompati" local minima dangkal saat learning rate tinggi, lalu berkonvergensi secara stabil saat learning rate turun.

3. Pada klasifikasi spesies ikan menggunakan CNN, penggunaan fungsi aktivasi ReLU tidak menunjukkan peningkatan akurasi setelah 50 epoch, meskipun learning rate telah dioptimasi. Jelaskan fenomena dying ReLU yang mungkin terjadi dan bagaimana hal ini mengganggu aliran gradien selama backpropagation!

Jawab:

Pada klasifikasi spesies ikan menggunakan CNN, ketika penggunaan fungsi aktivasi ReLU tidak menunjukkan peningkatan akurasi setelah 50 epoch meskipun learning rate telah dioptimasi, fenomena dying ReLU mungkin terjadi. Dying ReLU terjadi ketika neuron dengan aktivasi ReLU secara konsisten menghasilkan output nol karena input ke fungsi ReLU selalu negatif, menyebabkan gradiennya selalu nol. Neuron dengan ReLU yang "mati" berhenti belajar karena tidak ada gradien yang mengalir melaluinya, dan semakin banyak neuron "mati", semakin sedikit kapasitas model yang efektif digunakan. Dying ReLU mengganggu aliran gradien selama backpropagation karena gradien tidak dapat mengalir melalui neuron dengan aktivasi negatif. Jika neuron memasuki kondisi "mati", ia tidak akan diaktifkan kembali karena bobot tidak diperbarui. Hal ini menciptakan "bottleneck" dalam jaringan, di mana sebagian jalur pembelajaran menjadi tidak aktif, akibatnya kapasitas model efektif berkurang dan kemampuan untuk mempelajari representasi kompleks terhambat.

4. Pada pelatihan CNN untuk klasifikasi XX spesies ikan, grafik AUC-ROC menunjukkan satu kelas (Spesies X) stagnan di 0.55 sementara kelas lain mencapai >0.85 setelah YY epoch. Analisis mengapa class-weighted loss function gagal meningkatkan kinerja Spesies X, dan identifikasi tiga faktor penyebab potensial terkait karakteristik data dan arsitektur model!

Jawab:

Pada pelatihan CNN untuk klasifikasi spesies ikan, ketika grafik AUC-ROC menunjukkan satu kelas (Spesies X) stagnan di 0.55 sementara kelas lain mencapai >0.85 , hal ini menunjukkan masalah khusus dengan kelas tersebut. Kegagalan class-weighted loss function untuk meningkatkan kinerja Spesies X menunjukkan bahwa masalahnya lebih fundamental daripada sekadar ketidakseimbangan kelas. Pembobotan mungkin tidak cukup untuk mengatasi kompleksitas atau karakteristik unik dari data Spesies X. Tiga faktor penyebab potensial meliputi karakteristik data, ketidakseimbangan representasi, dan masalah arsitektur model. Karakteristik data spesies X mungkin memiliki variabilitas tinggi dalam penampilan (morfologi berbeda

berdasarkan usia, jenis kelamin, atau habitat), kualitas gambar yang buruk atau inkonsisten, atau kesamaan visual tinggi dengan spesies lain yang menciptakan ambiguitas. Ketidakseimbangan representasi dapat terjadi bila jumlah sampel tidak cukup untuk Spesies X dibandingkan dengan kompleksitas variasinya, distribusi subkelas tidak seimbang, atau kurangnya variasi dalam kondisi pengambilan gambar

5. Pada arsitektur CNN untuk klasifikasi ikan, peningkatan kompleksitas model justru menyebabkan penurunan akurasi validasi dari 85% ke 65%, meskipun akurasi training mencapai 98%. Jelaskan fenomena overfitting yang terjadi, dan mengapa penambahan kapasitas model tidak selalu meningkatkan generalisasi! Identifikasi 3 kesalahan desain arsitektur yang memicu degradasi performa

Jawab:

Pada arsitektur CNN untuk klasifikasi ikan, peningkatan kompleksitas model yang justru menyebabkan penurunan akurasi validasi dari 85% ke 65% meskipun akurasi training mencapai 98% menunjukkan fenomena overfitting yang serius. Model dengan kompleksitas tinggi memiliki kapasitas untuk "menghafal" data training daripada mempelajari pola umum, sehingga gagal menggeneralisasi ke data baru karena terlalu fokus pada fitur spesifik dataset training.

Penambahan kapasitas tidak selalu meningkatkan generalisasi karena sesuai prinsip Occam's Razor, model sederhana yang menjelaskan data dengan baik lebih disukai. Model kompleks memiliki ruang parameter lebih besar yang meningkatkan risiko overfitting, dan tanpa data training yang cukup, model kompleks akan mengisi "ketidakpastian" dengan noise. Meningkatkan kompleksitas tanpa teknik regularisasi yang tepat juga meningkatkan variance model.

Tiga kesalahan desain arsitektur yang memicu degradasi performa meliputi kedalaman berlebihan tanpa skip connection, ketidakseimbangan antara konvolusi dan pooling, serta regularisasi yang tidak memadai. Kedalaman berlebihan tanpa skip connection menyebabkan terlalu banyak lapisan konvolusi berurutan yang mengakibatkan masalah gradien dan "information bottleneck". Ketidakseimbangan antara konvolusi dan pooling terjadi bila terlalu sedikit pooling layer, ukuran filter tidak tepat, atau penurunan dimensi tidak efisien. Regularisasi yang tidak memadai meliputi kurangnya dropout, weight decay, atau teknik regularisasi lain, Batch Normalization yang diterapkan secara tidak tepat, tidak ada early stopping, atau data augmentasi yang tidak mencukupi. Untuk memperbaiki masalah ini, kita dapat mendesain arsitektur yang lebih seimbang, mengimplementasikan regularisasi yang tepat, menggunakan teknik ensemble, menghindari representasi "bottleneck" yang terlalu sempit, dan menerapkan transfer learning dari model pre-trained.