

Penjelasan Matematika

Berikut ini adalah rumus-rumus evaluasi model dan penjelasannya:

- **Binary Crossentropy Loss**

$$L = - [y \log(p) + (1 - y) \log(1 - p)]$$

Digunakan untuk menghitung kesalahan prediksi model klasifikasi biner. Nilai ini menunjukkan seberapa besar perbedaan antara label sebenarnya dan probabilitas prediksi model.

- **Akurasi (Accuracy)**

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

Mengukur rasio prediksi yang benar (baik positif maupun negatif) terhadap jumlah keseluruhan data.

- **Presisi (Precision)**

$$\text{Precision} = \frac{TP}{TP+FP}$$

Mengukur rasio prediksi positif yang benar dibandingkan dengan seluruh prediksi positif yang dibuat oleh model.

- **Recall (Sensitivity)**

$$\text{Recall} = \frac{TP}{TP+FN}$$

Mengukur seberapa baik model dalam menemukan semua contoh positif yang sebenarnya.

- **F1 Score**

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Merupakan rata-rata harmonik dari presisi dan recall. Digunakan saat kita ingin keseimbangan antara presisi dan recall.

- **AUC (Area Under Curve)**

Tidak memiliki rumus eksplisit sederhana, namun secara umum dihitung sebagai luas di bawah kurva ROC yang dibentuk dari plot nilai True Positive Rate vs False Positive Rate. AUC mendekati 1 berarti model sangat baik dalam membedakan antara kelas positif dan negative.

- **GRU Unit Math**

Gated Recurrent Unit (GRU) adalah varian dari RNN yang menggabungkan mekanisme *forget gate* dan *input gate* menjadi satu *update gate*, serta menggunakan *reset gate* untuk kontrol informasi:

$$\begin{aligned} z_t &= \sigma(W_z x_t + U_z h_{t-1} + b_z) \\ r_t &= \sigma(W_r x_t + U_r h_{t-1} + b_r) \\ \tilde{h}_t &= \tanh(W_h x_t + U_h(r_t \odot h_{t-1}) + b_h) \\ h_t &= (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \end{aligned}$$

- **LSTM Unit Math**

LSTM menyimpan memori jangka panjang menggunakan cell state, dan gate-gate untuk mengontrol aliran informasi.

$$\begin{aligned} i_t &= \sigma(W_i x_t + U_i h_{t-1} + b_i) \\ f_t &= \sigma(W_f x_t + U_f h_{t-1} + b_f) \\ o_t &= \sigma(W_o x_t + U_o h_{t-1} + b_o) \\ \tilde{c}_t &= \tanh(W_c x_t + U_c h_{t-1} + b_c) \\ c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t \\ h_t &= o_t \odot \tanh(c_t) \end{aligned}$$

- **RNN Standard Math**

RNN sederhana hanya mengandalkan hidden state yang diperbarui setiap waktu, namun rentan terhadap masalah vanishing gradient.

$$\begin{aligned} h_t &= \tanh(W x_t + U h_{t-1} + b) \\ y_t &= \sigma(V h_t + c) \end{aligned}$$